

合并指标方案（4组，原 86 项 → 合并后 80 项）

截至 2026-05-28

第 1 组 | M19 + M84（Token 消耗 + 冗长归一化）

字段	M19 (主)	M84 (并入)
中文名	Token 消耗	冗长归一化评分
n	655	655
mean	9.29 M	0.7313
ρ	0.294	0.9998 ← 与 eval_score 几乎完美共线
q	51	124
评级	B	A

问题：M84 = score / log(tokens+1), Spearman vs raw score = 1.000——本质上就是 eval_score 经过单调变换， $\rho=1$ 是计算副作用，不是独立信号。和已删的 J60（数据泄漏）同性质，但因为它至少绑定了 token 信息，可保留为 M19 的派生变体。
合并方式：把 M84 降级为 M19 的 **mvariant**（"按 token 归一化的得分视图"），M19 仍是主条目。

第 2 组 | J48 + J47（步骤召回率 + 步骤精确率）

字段	J48 (主)	J47 (并入)
中文名	步骤召回率	步骤精确率
n	655	655
mean	2.56	4.13
ρ	0.539	0.182
q	88	28
评级	A	C

理由：经典的 precision-recall 对，分开看不完整、合一起才有意义（F1 风格）。J48 信号更强（A 级），J47 弱（C 级）但作为对偶不可缺。
合并方式：J47 作为 J48 卡片的 " 配对指标 (Step Precision)" 内嵌区域（沿用 mVariant 渲染机制，但标签换成"配对"而非"原始比率变体"）。

第 3 组 | M78 + M79 + M80（三控制成功率）

字段	M78	M79	M80
中文名	Token 控制	Step 控制	Reasoning-Length 控制
公式	GLM(score~model+log(tokens)+task)	GLM(score~model+steps+task)	GLM(score~model+reasoning_len+task)
n	655	655	655
q	40	37	38
评级	C	C	C

理由：三者完全是同一统计方法（AlpacaEval-LC 控制变量回归），只是控制变量不同。分散三卡片冗余。
合并方式：单卡片"控制成功率族（M78 – 80）"，主卡显示综合 R^2 ，详情区按"控制变量 = {token / step / reasoning-len}"展开三行。

第 4 组 | M85 + M86 + M89（模型 × 属性元统计）

字段	M85	M86	M89
中文名	S ρ (m,a) Spearman	S σ (m,a) 标准差	Bucket 自诊断 argmax/argmin
n	380	275	275

字段	M85	M86	M89
mean	0.2225	15.996	15.899
ρ	meta	meta	meta
评级	C	C	C

理由：三者都是对 (model, attribute, bucket) 三元表格的元统计：M85 测单调性、M86 测离散度、M89 找极值。同一数据、不同投影，目前每个都单独 C 卡。

合并方式：单卡片"模型×属性元分析（M85/M86/M89）"，详情区三个子块（Spearman / σ / argmax-argmin）。

净效果

	现状	合并后
顶层卡片数	86	80
信息丢失	—	0（所有数据都在内嵌块）
同族指标聚合度	散	集中

不合并的（保留为独立卡片）

- J39 / J95 / J50 / J68 / J06 / J70 / J37 / J49（S/A 顶级 Judge）— 独立信号，强 ρ
- M02 / M14 / M20 / M43（独立 AUTO-RULE 测度）— 都是高 q 的独立物理量
- J13 / J25 / J30 / J40 / J42 / J63 / J64 / J73（带 mVariant 的 J 主指标）— 已经是合并形态
- M12 / M53（已经合并多个子项）— 不再扩展
- D 级低 q 但仍保留的：M05 / M07 / M11 / M12b / M15 / M16 / M23 / M26 / M53 / M54 / M55 / M57 / M58 / M71 / M72 / M74 / M93 / M94 — 弱信号但各有独立维度
- TBD 23 项——等实算后再决定

需要确认：4 组都执行？还是先做某一两组？